Porto Seguro Safe Driver Prediction

1. Razumevanje problema

Porto Seguro je jedna od najvećih osiguravajućih kompanija u Brazilu. Najveći poslovni izazov u oblasti auto osiguranja jeste precizna procena rizika pre nastanka štete. Cilj ovog projekta jeste izgradnja modela koji predviđa da li će određeni vozač u narednom periodu podneti zahtev za naknadu štete, na osnovu anonimnih podataka.

Precizno predviđanje rizičnih vozača kompaniji omogućava balansiranje cena polisa osiguranja: rizičniji vozači plaćaju veću premiju, dok bezbediniji vozači plaćaju manju premiju. Ovo direktno smanjuje finansijske gubitke kompanije.

Tip problema je binarna klasifikacija. Ciljna promenljiva target može imati vrednost 1 (vozač je podneo zahtev) ili 0 (vozač nije podneo zahtev). Kao glavna metrika evaluacije koristi se Normalized Gini koeficijent (Gini = 2 x AUC - 1). Accuracy se ne koristi zbog izražene nebalansiranosti klasa u skupu podataka.

2. Razumevanje podataka

Skup podataka potiče sa Kaggle takmičenja Porto Seguro Safe Driver Prediction i sadrži 595212 primera u skupu za obučavanje i 892816 primera u test skupu. Svaka opservacija odgovara jednom vozaču. Skup ima 59 kolona, od kojih su 57 atributi, jedna kolona predstavlja identifikator (id) i jedna je ciljna promenljiva (target).

Atributi su potpuno anonimni. Porto Seguro je definisao kovenciju imenovanja koja određuje tip svakog atributa. Sufiksi _bin označavaju binarne promenljive, _cat kategoricke, dok kolone bez sufiksa predstavljaju numeričke atribute. Prefiksi ps_ind_ odnose se na podatke o osiguraniku, ps_reg_ na podatke o registraciji, ps_car_ na karakteristike vozila, a ps_calc_ na izvedene vrednosti.

Prvo zapažanje je da skup podataka naizgled nema NaN vrednosti, što je neobično za realne podatke. Kaggle dokumentacija otkriva da vrednost -1 predstavlja nedostajuće vrednosti. Ukupno 13 kolona sadrži nedostajuće vrednosti, pri čemu se posebno ističu ps_car_03_cat sa 69.09% i ps_car_05_cat sa 44.78% nedostajućih vrednosti. Analiza raspodele ciljne promenljive pokazuje izraženu nebalansiranost klasa. Svega 3.64% vozaca (21694 od 595212) pripada pozitivnoj klasi.

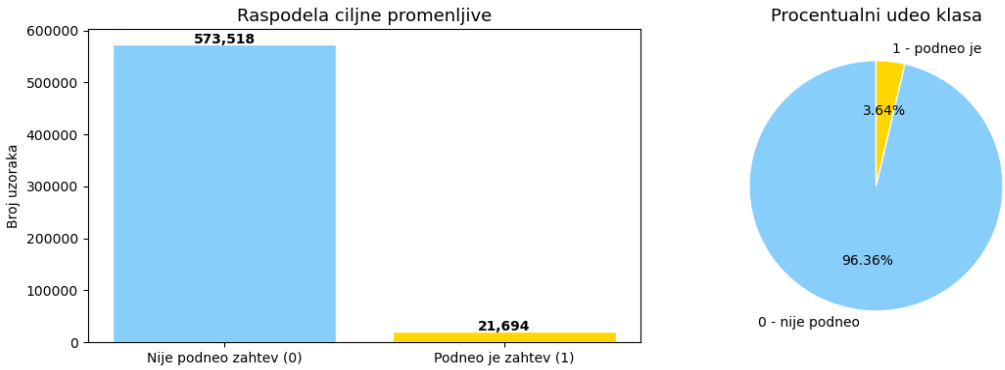

Slika 1: Raspodela ciljne promenljive

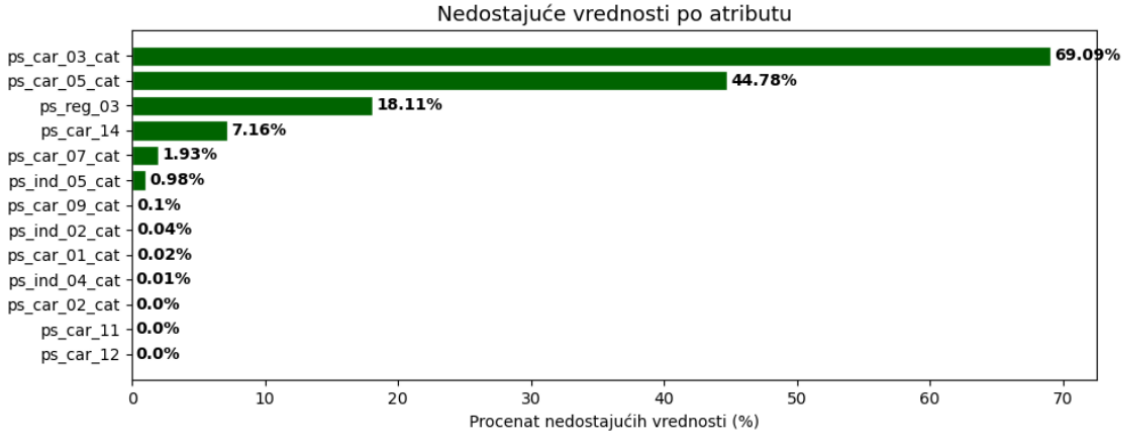

Slika 2. Procenat nedostajućih vrednosti

3. Priprema podataka

Priprema podataka sprovedena je uz posebnu pažnju da se izbegne curenje informacija između trening i test skupa. Ključno pravilo je da se podela na trening i test skup uvek vrši kao prvi korak, pre svih transformacija koje uče iz podataka. Sve transformacije fituju se iskljucivo na trening skupu i potom primenjuju na test skup.

Podela je izvršena stratifikovano (stratify=y) sa odnosom 80/20, čime je garantovana ista zastupljenost pozitivnih primera u oba skupa. Za atribute sa visokim procentom nedostajućih vrednosti (ps_car_03_cat, ps_car_05_cat, ps_reg_03, ps_car_14) kreirani su binarni atributi koji označavaju prisustvo nedostajuće vrednosti. Hipoteza je da odsustvo podatka samo po sebi moze biti prediktor.

Nakon kreiranja atributa, vrednosti -1 su zamenjene sa NaN i sprovedena je imputacija. Za numeričke atribute korišćena je medijana (robusna na outlier-e), a za kategoričke modus. Kategorički atribut ps_car_11_cat sa 104 kategorije tretiran je target encoding-om. Preostali kategorički atributi kodirani su one-hot encoding-om, uz align() funkciju kojom se garantuje ista struktura kolona u oba skupa. Za modele osetljive na skalu (Logistic Regression, KNN) primenjen je StandardScaler.

4. Početni modeli

4.1 Poređenje početnih modela

U prvoj fazi trenirani su osnovni klasifikacioni modeli: Logistic Regression (logistička regresija), K-Nearest Neighbors (k-najbližih suseda) i Decision Tree (stablo odlučivanja). Logistic Regression se istakla kao najjači baseline model sa AUC = 0.6386. što sugeriše da u podacima postoji određeni linearan signal. Decision Tree bez ograničenja dubine pokazao je jasne znakove overfitting-sa, sa AUC vrednoscu svega 0.5084 na test skupu, što je za nijansu bolje od nasumičnog pogađanja. KNN se pokazao malo bolji od Decision Tree-a sa AUC vrednošću od 0.5191. Dobijeni rezultati početnih modela predstavljali su osnovu za narednu fazu analize, u kojoj je fokus na konstrukciji novih i izbor najinformativnijih atributa.

5. Konstrukcija i izbor atributa

5.1 Konstrukcija atributa

Zbog anonimnosti skupa podataka, konstrukcija atributa se oslanja isključivo na strukturu podataka i konvenciju imenovanja. Kreirane su četiri klase novih atributa:

- fe_missing_count koji prebrojava ukupan broj nedostajucih vrednosti po vozacu,
- zbir binarnih atributa po grupama (fe_bin_sum, fe_ind_bin_sum, fe_calc_bin_sum),
- prosek i standardna devijacija numeričkih atributa po semantičkim grupama;

- proizvodi visoko korelisanih parova atributa unutar iste grupe (fe_car12_x_car13, fe_reg01_x_reg03 i dr.).

Konstrukcija atributa je doprinela blagom poboljšanju performansi kod svih posmatranih modela, što ukazuje da novokreirani atributi nose dodatnu informaciju korisnu za klasifikaciju.

5.2 Selekcija atributa

Primenjena su tri pristupa selekciji atributa. Filter metoda (SelectKBest + Mutual Information) procenjuje svaki atribut izolovano. Embedded metoda (Random Forest Feature Importance) procenjuje atribute u kontekstu celog modela uzimajući u obzir interakcije. Wrapper metoda (RFE sa Logistic Regression) iterativno uklanja atribute sa najmanjim koeficijentima.

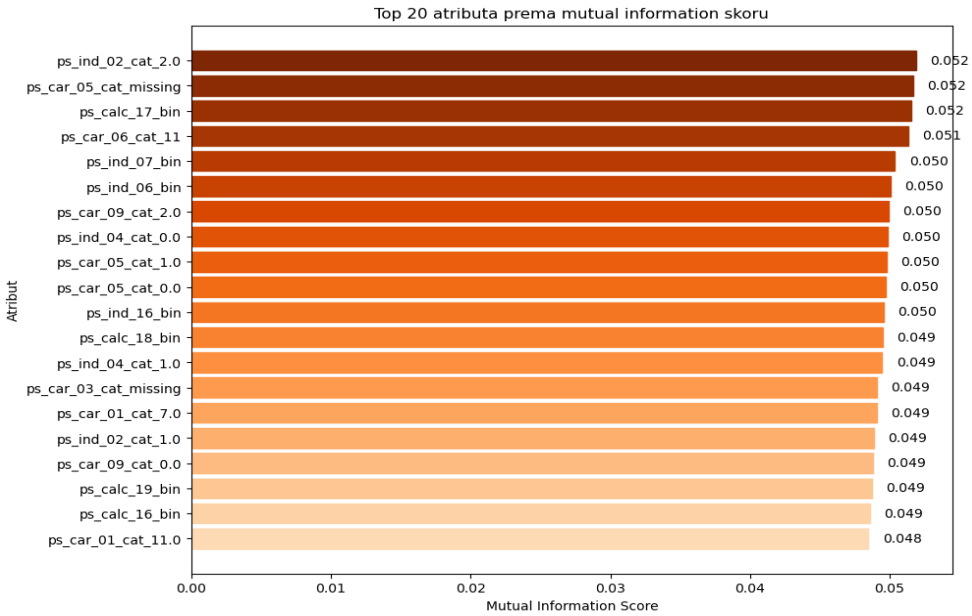

Slika 3: Top 20 atributa prema Mutual Information skoru

Na osnovu preseka metoda formirana su dva skupa atributa: fs_1plus (atributi izabrani od najmanje jedne metode) i fs_2plus (atributi izabrani od najmanje dve metode). Među najznačajnijim atributima prema embedded metodi nalaze se i atributi kreirani u fazi konstrukcije atributa, što retroaktivno potvrđuje korisnost izvršenih transformacija.

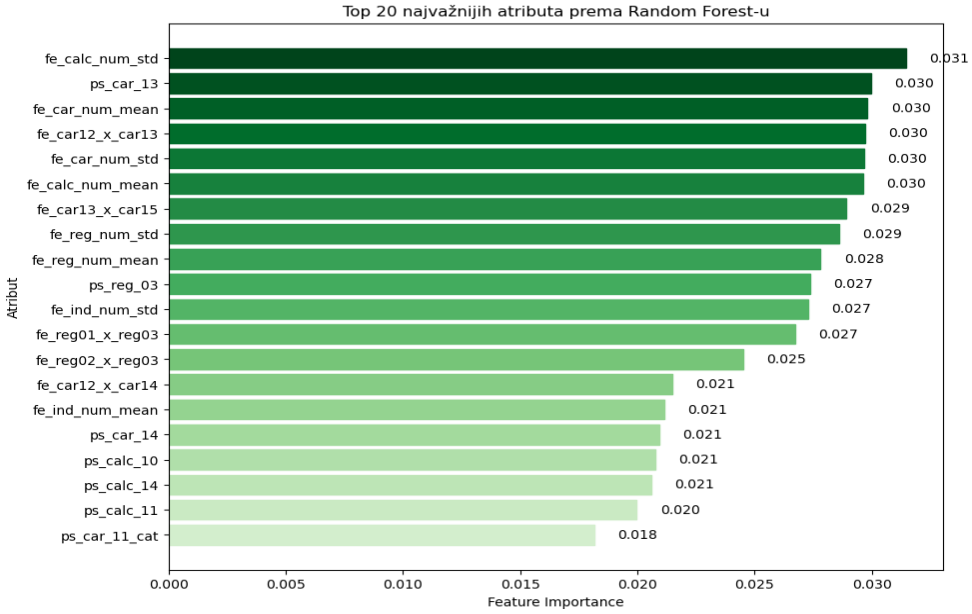

Slika 4: Top 20 atributa prema Random Forest feature importance-u

6. Modelovanje i evaluacija

6.1 Evaluacija modela na skupovima podataka

Nakon konstrukcije i selekcija atributa, testirani su modeli nad novim skupovima fe, fs_1plus i fs_2plus, kako bi se procenio uticaj različitih reprezentacija podataka na njihove performanse. Logistic Regression je zadržala najbolje rezultate među osnovnim modelima na svim skupovima atributa, pri čemu je najbolji rezultat ostvaren na skupu fe (AUC = 0.6406, Gini = 0.2811). Modeli KNN i Decision Tree ostvarili su znatno slabije performanse, a dodatno smanjenje broja atributa, posebno na skupu fs_2plus, dovelo je do daljeg pada kvaliteta. Skup podataka fs_2plus je izostavljen iz dalje analize jer ne prikazuje zadovoljavajuće rezultate.

	Model	AUC	Gini
0	LogReg (fe)	0.640551	0.281102
1	LogReg (fs_1plus)	0.640244	0.280488
2	LogReg (fs_2plus)	0.614937	0.229874
3	KNN (fe)	0.520254	0.040507
4	KNN (fs_1plus)	0.520239	0.040478
5	KNN (fs_2plus)	0.508287	0.016573
6	Decision Tree (fe)	0.508282	0.016564
7	Decision Tree (fs_1plus)	0.505830	0.011661
8	Decision Tree (fs_2plus)	0.504848	0.009696

Slika 4: Poređenje performansi modela

6.2 Napredni modeli i optimizacija hiperparametara

U drugoj fazi primenjeni su ansambl modeli Random Forest i XGBoost, evaluirani nad tri skupa podataka primenom stratifikovane 5-fold kros validacije. Optimizacija hiperparametara sprovedena je primenom RandomizedSearchCV sa 30 iteracija, pretrazujuci prostor parametara: n_estimators, max_depth, learning_rate, subsample, colsample_bytree, min_child_weight i gamma. Optimizacija je sprovedena nad skupovima fe i fs_1plus.

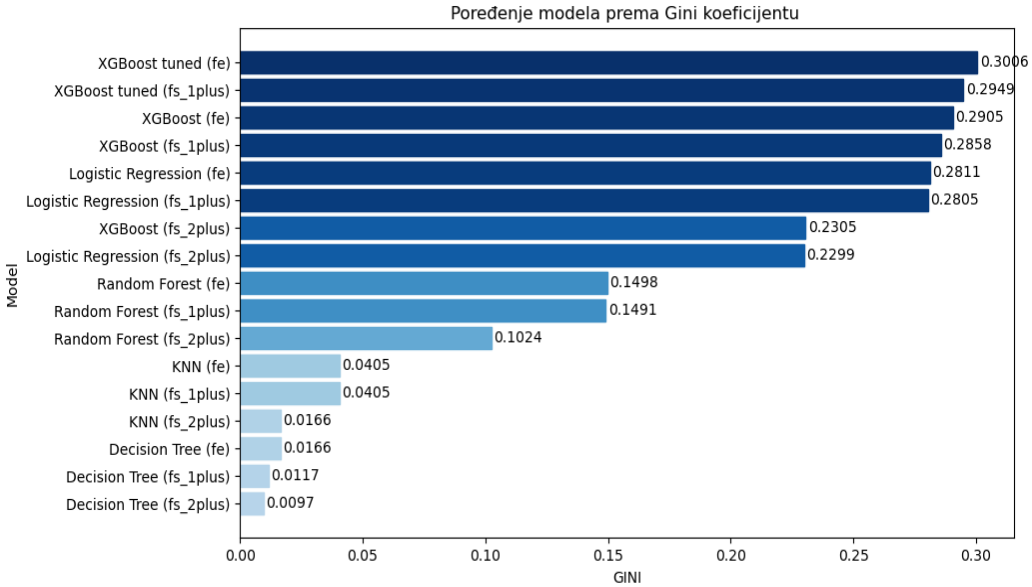

Slika 5: Graficko poredenje svih modela prema Gini koeficijentu

6.3 Finalna evaluacija

Finalni model je optimizovani XGBoost treniran na kompletnom fe skupu atributa (AUC = 0.6503, Gini = 0.3006). ROC kriva prikazana je u nastavku. Kriva se jasno nalazi iznad dijagonale koja predstavlja nasumično predviđanje, što potvrđuje diskriminativnu moć modela.

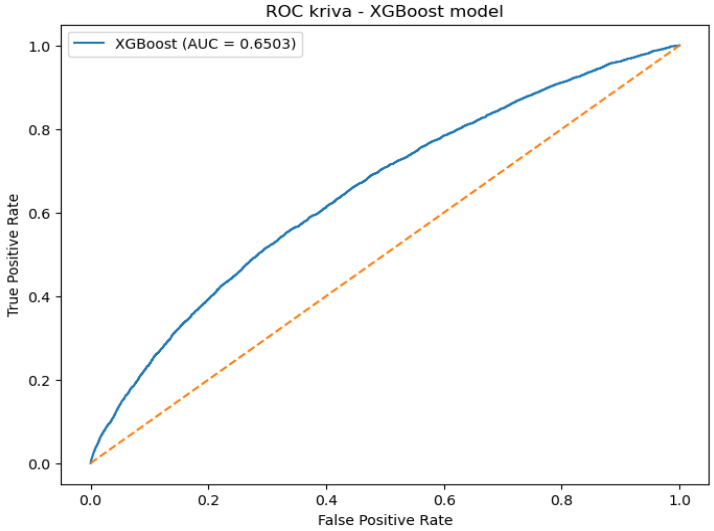

Slika 6: ROC kriva finalnog XGBoost modela (AUC = 0.6503)

7. Zaključak i budući pravci

U okviru ovog rada analiziran je problem binarne klasifikacije primenom CRISP-DM metodologije. Optimizovani XGBoost model treniran na kompletnom skupu atributa nakon feature engineering-a ostvario je najbolje performanse (AUC = 0.6503, Gini = 0.3006). Logistic Regression se pokazala kao iznenađujuće jak model, zbog čega bi bilo korisno dodatno razmotriti njeno unapređenje kroz optimizaciju hiperparametara.

Kao predlog za moguća unapređenja u budućim istraživanjima mogu se izdvojiti primena tehnika balansiranja klasa, kao što su SMOTE i class_weight tehnike, koje u ovom radu nisu korišćene, kao i veći broj iteracija u postupku RandomizedSearchCV radi preciznije optimizacije hiperparametara. Kao dodatni pravac, moglo bi se razmotriti i podešavanje praga odlučivanja u skladu sa konkretnim poslovnim ciljevima kompanije, jer bi preciznije i pravovremenije prepoznavanje rizičnih osiguranika pomoglo u smanjenju finansijskih gubitaka.